



PROJET INDIVIDUEL

PJI (54) - Mais que font nos députés ? Une sociologie informatique du travail parlementaire

Auteur : Quentin BAERT
Encadrant universitaire : Samuel HYM
Encadrant : Etienne OLLION

janvier à juin 2015

Sommaire

Remerciements	2
Introduction	3
1 Objectifs du projet	4
2 Choix des outils	5
2.1 Le langage Scala	5
2.2 SBT (Scala Build Tool)	5
3 Récupération des comptes rendus intégraux	7
3.1 Organisation des PDFs sur le site de l'Assemblée nationale . .	7
3.2 Récupération des PDFs	8
4 Transformation des PDFs	9
4.1 Conversion des PDFs en fichiers textes	9
4.2 Analyse des fichiers textes pour isoler les scrutins	9
5 Mise en forme des informations récupérées	10
5.1 Représentation objet d'un scrutin	10
5.2 Extraction des données des scrutins	10
5.3 Nettoyage des données	10
6 Construction des bases de données	11
Conclusion	12
Bibliographie	13

Remerciements

Merci à Samuel Hym et Etienne Ollion pour leur accessibilité, leur bienveillance, leur suivi et pour avoir répondu à chacune de mes questions.

Introduction

Le PJI (Projet individuel) se déroule dans le cadre de la première année de master informatique à l'Université de Lille 1. Le but est ici de développer un projet sur l'ensemble d'un semestre.

Ce rapport concerne le projet numéro 54, intitulé "Mais que font nos députés ? Une sociologie informatique du travail parlementaire" et encadré par messieurs Samuel Hym, enseignant chercheur au laboratoire CRISStAL de Lille, et Etienne Ollion, chercheur CNRS au laboratoire SAGE de Strasbourg.

Le but de ce projet est d'exploiter les comptes rendus intégraux de l'Assemblée nationale française afin de constituer des bases de données qui contiennent les informations des scrutins qui y sont votés : numéro, date, sujet du scrutin ainsi que nom, prénom, parti et vote des députés participants au scrutin.

Ce rapport présentera l'ensemble des travaux effectués sur le projet ainsi que leurs résultats. Pour commencer, le choix des outils utilisés sera exposé et justifié. Nous aborderons ensuite la manière dont les comptes rendus de l'Assemblée nationale ont été récupérés. Puis, nous verrons comment ces comptes rendus ont été filtrés et mis en forme afin de pouvoir en exploiter les données. Enfin, nous verrons comment les données ont été extraites et nettoyées afin de créer les bases.

1 Objectifs du projet

L'objectif de ce projet est de collecter l'ensemble des scrutins publics tenus à l'Assemblée nationale entre 1958 et 2002 et de les organiser dans une base de données. Les données initiales doivent être extraites de documents PDFs, nettoyées et présentées sous forme d'une base facilement interrogeable (sous forme d'un fichier CSV par exemple).

Les différentes étapes sont donc de :

1. récupérer tous les PDFs des comptes rendus intégraux sur le site de l'Assemblée nationale
2. convertir ces PDFs en fichiers textes afin de pouvoir facilement travailler sur le contenu des comptes rendus
3. filtrer les fichiers pour isoler ceux qui concernent des scrutins
4. créer des fichiers CSV à partir des fichiers qui contiennent en effet un ou plusieurs scrutins

La mise en place et les résultats de ces différentes étapes sont présentés dans la suite de ce rapport.

2 Choix des outils

Le sujet du projet n'impose aucune technologie particulière pour répondre aux différents objectifs, quelques objectifs personnels ont donc été ajouté aux différents objectifs du projet. L'un de ces buts personnels est d'uniquement utiliser le paradigme de programmation fonctionnel. C'est cette contrainte qui motive l'utilisation des outils suivants.

2.1 Le langage Scala

Scala est un langage de programmation multi-paradigme qui compile sur la Java Virtual Machine.

Ce langage est utilisé pour ce projet car il intègre complètement les paradigmes de programmation orientée objet et de programmation fonctionnelle, le tout avec un typage statique. Cela permet dans un premier temps de retrouver des reflexes développés grâce à la pratique du Java et dans un second temps de continuer à découvrir le paradigme fonctionnel.

De plus, Scala est un langage qui compile sur la JVM. Il est donc possible d'utiliser les bibliothèques Java au sein d'un code écrit en Scala. Des classes écrites dans ces deux langages peuvent même être mixées dans un même projet, laissant ainsi la possibilité d'écrire du code en Java si le besoin apparaît.

2.2 SBT (Scala Build Tool)

SBT ou Scala Build Tool est un outil open source qui aide à construire une application Scala (potentiellement mixé avec des sources Java). Cet outil permet de compiler facilement un projet Scala, facilite l'intégration de librairie extérieures ou de framework de tests. Il intègre également un interpréteur Scala.

Il est compliqué d'écrire une suite de tests afin de vérifier le code écrit pour ce projet. Le code est fortement spécifique aux documents de l'Assemblée nationale. De plus, il n'est au final destiné qu'à être exécuté une seule fois pour récupérer les bases de données. Le test de l'application est donc d'obtenir les résultats attendus pour les documents étudiés.

Pour ces raisons et car le projet ne nécessite pas de livrer un exécutable, SBT est grandement utile. Il permet notamment de suivre le cycle de travail suivant : écrire le code, compiler les sources, démarrer l'interpréteur, créer les

objets nécessaires grâce aux documents et lancer directement le traitement.

3 Récupération des comptes rendus intégraux de l'Assemblée nationale

La première étape du projet est de récupérer les comptes rendus intégraux de l'Assemblée nationale depuis son site internet (<http://archives.assemblee-nationale.fr>) pour en extraire les données par la suite. Les sources du code qui sert à répondre à cette problématique se trouvent dans le package `download`.

3.1 Organisation des PDFs sur le site de l'Assemblée nationale

Les PDFs à récupérer sont ceux des comptes rendus intégraux tenus entre 1958 et 2002. Cela représente une période qui s'étend de la première à la onzième législature.

Le site de l'Assemblée nationale est organisé de la manière suivante : une page d'index par législature, chaque page d'index pointe sur des pages de sessions dans lesquels se trouvent les liens vers les PDFs. Par exemple pour la dixième législature, on observe l'arborescence suivante :

```
10/cri/index.asp
|_ 10/cri/10-1996-1997-ordinaire1.asp
   |_ 10/cri/1996-1997-ordinaire1/001.pdf
   |_ 10/cri/1996-1997-ordinaire1/002.pdf
   |_ ...
|_ 10/cri/10-1995-1996-ordinaire1.asp
|_ ...
|_ 10/cri/10-1992-1993-extraordinaire3.asp
```

Où `index.asp` est la page d'index de la dixième législature, `10/cri/10-1996-1997-ordinaire1.asp` un exemple d'URL de page de session et `10/cri/1996-1997-ordinaire1/001.pdf` un exemple d'URL de PDF.

Dans un premier temps, nous pensons à générer chacun des URLs des PDFs automatiquement en intégrant la logique de l'arborescence. Cependant, nous remarquons rapidement que certaines irrégularités nous feraient passer à côté de PDFs. Il existe par exemple des PDFs nommés `14a.pdf` et dont on ne peut prévoir l'apparition dans l'arborescence.

Afin de récupérer tous les URLs sans exceptions, nous avons décidé de récupérer le code HTML des pages d'index, d'y isoler les URLs des pages de sessions, de les convertir en chaîne de caractères et de filtrer leur contenu pour ne préserver que les URLs des PDFs. Ce traitement est exécuté par l'objet `URLManager` qui fournit, à travers son champ `pdfURLs`, la liste des URLs de tous les PDFs.

Diagramme de classe ?

3.2 Récupération des PDFs

Une fois tous ces URLs recensés, il est facile de tous les télécharger. L'objet `PDFDownloader` possède une méthode `downloadAll` qui permet de télécharger chacun des PDFs ou d'afficher un message en cas d'erreur de téléchargement. Cependant, étant donné que 8691 URLs ont été récupérés par l'objet `URLManager`, une autre méthode `downloadGroupNb` permet de télécharger les PDFs uniquement par groupe de 100 (ces groupes sont numérotés de 0 à 85). Dans notre cas, nous téléchargeons 1000 PDFs par jour, cela permet de rester courtois et de ne pas surcharger les serveurs de requêtes.

Une autre problématique est de garder une organisation locale proche de celle du site internet afin de pouvoir s'y retrouver au milieu de ces milliers de PDFs. Pour cela, l'URL du PDF est légèrement modifié pour obtenir son chemin local qui est du type : `cri/<législature>/<années>/<session>/<nom>.pdf`.

Après le téléchargement de ces quelques 8000 PDFs, tous les comptes rendus de l'Assemblée nationale de la première à la onzième législature se trouvent en local sur notre machine. Reste maintenant à trouver un moyen de filtrer et exploiter ces 17 giga octets de données.

4 Transformation des PDFs

4.1 Conversion des PDFs en fichiers textes

4.2 Analyse des fichiers textes pour isoler ceux contenant des scrutins

5 Mise en forme des informations récupérées

5.1 Représentation objet d'un scrutin

5.2 Extraction des données des scrutins

5.3 Nettoyage des données

6 Construction des bases de données

Conclusion

Bibliographie